



Εφιάλτης στην Κουζίνα

Food Hazard Detection — SemEval-2025 Task 9, ST1

AM 4940 — Φουρκιώτης Αθανάσιος

To task

Έχω ως είσοδο μια αναφορά ανάκλησης τροφίμου (`title + text + metadata`) και πρέπει να προβλέψω δύο labels:

- `hazard-category` (10 κλάσεις: allergens, biological, foreign bodies, ...)
- `product-category` (22 κλάσεις: meat, dairy, prepared dishes, ...)

Scoring:

$$ST1 = \frac{\text{macroF1}(\text{hazard}) + \text{macroF1}(\text{product} \mid \text{hazard σωστό})}{2}$$


Το product μετράει **μόνο** όταν έχω βρει σωστά το hazard → οπότε σκέφτηκα φυσική αρχιτεκτονική 2 σταδίων.

Τα δεδομένα

Train: 5.082 — **Validation:** 565 — **Test:** 997 (Kaggle)

Pooled: 5.647 παραδείγματα για cross-validation

Strongly **imbalanced** — μεγάλη variance στο macro-F1



Πώς έφτιαξα τα features

Σύνθεση κειμένου που έφτιαξα: `metadata + " | " + title + " " + text (lowercase)`. Πρόσθεσα metadata tokens: `country_*`, `year_*`, `month_*`.

TF-IDF (2 vectorizers stacked):


- Word n-grams (1, 2) → ~94k features
- Char_wb n-grams (3, 5) → ~165k features
- Συνολικά **~160k sparse features**

MiniLM-L6-v2 sentence embeddings που έβαλα:


- 384-dim dense, L2-normalized
- Cached σε `results/cache/emb_minilm_*.npy`
- Stacked × **scale 0.7** δίπλα στο TF-IDF

Scale sweep — U-shape

Έκανα sweep στο scale των embeddings στο $[0, 0.2, 0.3, 0.5, 0.7, 1.0]$ και βρήκα **U-shape**: στο 0 χάνεται σημασιολογία, στο 1.0 τα dense embeddings κυριαρχούν τα sparse TF-IDF.



Η αρχιτεκτονική Εφιάλτης Στην Κουζίνα



Γιατί OOF hazard predictions


Δεν χρησιμοποίησα ground-truth hazard στο product training. Έκανα 5-fold cross-validation στο train ώστε κάθε row να πάρει hazard prediction από μοντέλο που **δεν** το είδε.

Διαίσθηση: στο test το hazard μοντέλο θα είναι ~94% σωστό, όχι 100%. Αν στο train το product βλέπει 100% σωστό hazard, μαθαίνει να εμπιστεύεται τυφλά το hazard — και στο test που είναι λάθος, σωριάζεται. Με OOF, το product βλέπει «ρεαλιστικό» hazard signal με την ίδια ποιότητα θορύβου που θα δει στο test.

Classical baselines — Validation scores

Μοντέλο	ST1
TF-IDF + LogReg	0.6875
TF-IDF + ComplementNB	0.5139
TF-IDF + SVD600 + LinearSVC	0.6771
TF-IDF + SVD300 + MLP	0.5369
TF-IDF + LinearSVC	0.7599
+ metadata + C tuning	0.7612
+ OOF hazard one-hot (Εφιάλτης)	0.7623
+ MiniLM × 0.7 (09_embeddings)	0.7737

Validation vs Kaggle — To pattern



Άλλαξα τρόπο: cross-validation

Έτρεξα 5-fold StratifiedKFold στο pooled (5.647 rows):

- Εφιάλτης TF-IDF baseline: **CV ST1 = 0.7036 ± 0.0516**

Δηλαδή το «καλό» valid score 0.7623 ήταν πάνω από 1 standard deviation από τον CV μέσο όρο — lucky draw.

Όλα τα single-split «improvements» που είχα δοκιμάσει (no metadata, διαφορετικά C, διαφορετικά hazard weights) έπεσαν εντός **0.007** μεταξύ τους. Άρα κατάλαβα ότι σε αυτό το dataset **μόνο** CV-validated βελτιώσεις έχουν αξία.



Kaggle public score:
0.77750 (+0.0202 από το
προηγούμενο
best). Πρώτη φορά που
μια CV-validated
βελτίωση πέρασε και
στο Kaggle.


Επιπλέον προσπάθειες που δοκίμασα 6 και καμία δεν πέρασε

Με Kaggle 0.77750, έβαλα
στόχο το 0.80. Δοκίμασα 6
προσεγγίσεις:

Πείραμα	CV gain	Folds +	Kaggle Δέλτα
3-way v2 (single-split tuning)	—	—	−0.012
DistilBERT v3 single fine-tune	—	—	−0.041
3-way v3 (proper CV OOF DistilBERT)	+0.018	4/5	−0.013
DeBERTa-v3 5- fold OOF	—	—	NaN
mpnet swap (× 0.7)	+0.031	5/5	−0.015
Hybrid weighted majority vote	—	—	−0.010

Σύγκριση DistilBERT vs MiniLM (failed experiment 2)

Στο DistilBERT v1 πήγα με την προσδοκία να ανέβει το score αρκετά (στόχος ~0.79-0.82). Πήρα ST1=0.6723, **0.10 ΚΑΤΩ** από το Εφιάλτης + MiniLM.



απο πανω μου θα κατσεις



Ευχαριστώ!! Ερωτήσεις;

σαν τον βρυκολακα;